

移动端模型优化与部署研究

实习实训项目报告

答辩学生: 王德阳

HiFi-GAN理论理解和验证

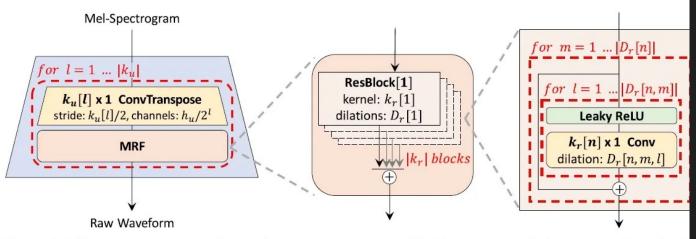


Figure 1: The generator upsamples mel-spectrograms up to $|k_u|$ times to match the temporal resolutio of raw waveforms. A MRF module adds features from $|k_r|$ residual blocks of different kernel size and dilation rates. Lastly, the n-th residual block with kernel size $k_r[n]$ and dilation rates $D_r[n]$ in MRF module is depicted.

```
class Generator(torch.nn.Module):
   def __init__(self, h):
       super(Generator, self).__init__()
       self.num_kernels = len(h.resblock_kernel_sizes)
       self.num_upsamples = len(h.upsample_rates)
       self.conv_pre = weight_norm(Conv1d(80, h.upsample_initial_channel, 7, 1, padding=3))
       resblock = ResBlock1 if h.resblock == '1' else ResBlock2
       self.ups = nn.ModuleList()
       for i, (u, k) in enumerate(zip(h.upsample_rates, h.upsample_kernel_sizes)):
           self.ups.append(weight_norm(
               ConvTranspose1d(h.upsample_initial_channel//(2**i), h.upsample_initial_channel//(2**(i+1)),
                               k, u, padding=(k-u)/(2))
       self.resblocks = nn.ModuleList()
       for i in range(len(self.ups)):
           ch = h.upsample_initial_channel//(2**(i+1))
           for j, (k, d) in enumerate(zip(h.resblock_kernel_sizes, h.resblock_dilation_sizes)):
               self.resblocks.append(resblock(h, ch, k, d))
       self.conv_post = weight_norm(Conv1d(ch, 1, 7, 1, padding=3))
       self.ups.apply(init_weights)
       self.conv_post.apply(init_weights)
   def forward(self, x):
       x = self.conv_pre(x)
       for i in range(self.num_upsamples):
           x = F.leaky_relu(x, LRELU_SLOPE)
           x = self.ups[i](x)
           xs = None
           for j in range(self.num_kernels):
               if xs is None:
                   xs = self.resblocks[i*self.num_kernels+j](x)
                   xs += self.resblocks[i*self.num_kernels+j](x)
           x = xs / self.num_kernels
       x = F.leaky_relu(x)
       x = self.conv_post(x)
       x = torch.tanh(x)
       return x
   def remove weight norm(self):
       print('Removing weight norm...')
       for l in self.ups:
           remove_weight_norm(l)
       for l in self.resblocks:
           l.remove_weight_norm()
       remove_weight_norm(self.conv_pre)
       remove_weight_norm(self.conv_post)
```



HiFi-GAN理论理解和验证



		输入的数据为由wav音频通过wav, sr =		1	Pre-processing Convolution (batch_size, 80,	(batch_size, 512, (512, 80, 7)		
		load_wav(os.path.join(a.input_wavs_di		E9 🛕	input length) // fx 有提供int8版本的算子	output length) (512, 56, 7)		
		r, filname))提取出来的一维的列表,	_	<u> </u>				
		类似[-9 0 029-32-36],通过	4	A	В	C	D	E
		wav =	2	onnx算子	说明	对应的nn库算子	简略分析	结论
HIFIGAN	Inference from wav file	torch.FloatTensor(wav).to(device)转换 后,尺寸变为torch.Size([41885]), x = get_mel(wav.unsqueeze(0))使其变为 torch.Size([1,80,163]),便于后续算 子的输入。(第三维的长度作为数据 的长度并不固定,但前两个维度的值	y_g_hat = ger y_g_hat尺寸岁 1,41728](第 为数据的长度 前两个维度 的),再过 y_g_hat.squee 维度,于 torch.Size([41] 成列表,最终	Identity	这个算子返回的是输入本身,不做任何修改	Nop	nn_node_ops nn_ops_for_Nop 这个节点是一个无操作的占位符节点,没有特定的数据类型限制。	不受数据类型限制
					这个算子增加输入张量的维度,但不增加新的元素	Reshape、ExpandDims	"QuantizedReshape": 输入数据是量化的8位整数(8-bit quantized)数据。 输出数据类型也是量化的8位整数。	int8版本的算子
		是确定的)		Unsqueeze			ExpandDims_int32用于处理int32类型的张量数据,它将输入张量复制到输出张量中,没有进行任何实际操作。该节点支持1到3个输入张量和1个输出张量。 ExpandDims_f用于处理float类型的张量数据,同样也是将输入张量复制到输出张量中,没有进行任何实际操作。该节点也支持1到3个输入张量和1个输出张量。	
	Inference for end-to-end speech synthesis	通过x = np.load(os.path.join(a.input_mels_dir, filname))输入,得到的其尺寸为(1,80, 186),通过wav = torch.FloatTensor(wav).to(device)转换 后,尺寸变为torch.Size([1,80,186]) (第三维的长度作为数据的长度并不 固定,但前两个维度的值是确定的)		Conv	这是卷积运算的算子,主要在卷积神经网络(Convolutional Ne Networks,CNNs)中使用	QuantizedConv2d_8x8to32、 QuantizedConv2d_16x16to32	nn_ops_for_QuantizedConv2d_8x8to32: 这个算子执行的是8位整数(int8)量化的卷积操作。它接受8位整数格式的输入张量, 执行卷积计算,并将结果输出为32位整数格式的张量。	
				Relu	这是ReLU(Rectified Linear Unit)激活函数的算子	QuantizedRelu_8	nn_ops_for_QuantizedRelu_8和nn_ops_for_QuantizedRelu_8_ref: 输入和输出数据类型为quint8(8位无符号整数)。这是用于量化修正线性单元的节点操作。nn_ops_for_QuantizedReluX 8_ref: 输入数据类型为quint8(8位无符号整数),输出数据类型为quint8(8位无符号整数)。这是用于量化修正线性单元(带上限值)的节点操作。	有提供int8版本的算子
				Transpose	这个算子将输入张量的维度进行转置	Transpose_x	OP_Transpose_8: 輸入和輸出数据类型为quint8 (8位无符号整数)	有提供int8版本的算子
				Constant	这个算子生成一个常数张量	Const	nn_ops_for_Const 常量节点的输出数据类型由数据本身的大小决定,当数据大小为1字节时,输出数据类 型为quint8(8位无符号整数)。	有提供int8版本的算子
			g	Reshape	这个算子改变输入张量的形状,但不改变其元素	Reshape QuantizedReshape	"QuantizedReshape": 输入数据是量化的8位整数(8-bit quantized)数据。 输出数据类型也是量化的8位整数。	有提供int8版本的算子
			1	Pow	这个算子执行幂运算	Mul_f 、QuantizedMul_8x8to32	QuantizedMul_8x8to8: 操作: 量化的8位整数乘法、结果为8位整数。	有提供int8版本的算子
			1	Cast	这个算子用于改变输入张量的数据类型	Convert_to_aix_d32、Convert_from_d32、Convert_to_d32	Convert_8_16 / Convert_8_u16: 将输入的uint8类型数据转换为int16或uint16类型数据。 Convert_16_8 / Convert_u16_8: 将输入的int16或uint16类型数据转换为uint8类型数据。	不受数据类型限制
			1	Div	这个算子执行张量的元素级别的除法	Div_f	QuantizedDiv_8操作,用于对两个量化的输入数据进行除法运算。在代码中,数据类型主要使用了uint8_t,也同样会使用float。	
			1	Sub	这个算子执行张量的元素级别的减法	Sub_f. Sub_int32	QuantizedSub_8p8to8用于处理8位量化数据的减法。	有提供int8版本的算子
			1	MatMul	这个算子执行矩阵乘法	QuantizedMatMu1_8x8to32	nn_ops_for_QuantizedMatMul_8x8to32 nn_ops_for_QuantizedBatchMatMul_8x8to32 nn_ops_for_QuantizedMatMul_8x8to32_ref 这三个结构体定义是针对矩阵乘法运算的操作,其中输入数据和输出数据的数据类型为 8位整数、输出为32位。	
			1	Add	这个算子执行张量的元素级别的加法	Add_f、Add_int32	QuantizedAdd_8p8to8用于处理8位量化数据的加法。	有提供int8版本的算子
			1	ReduceMean	这个算子计算输入张量的所有元素的平均值	QuantizedMean_8	用于执行量化的均值(mean)计算的节点操作(nn_ops_for_QuantizedMean_8)。这个节点操作用于处理8位量化数据。	有提供int8版本的算子
			1	Sqrt	这个算子计算输入张量每个元素的平方根	QuantizedSqrt_8	用于执行量化的平方根(sqrt)计算的节点操作(nn_ops_for_QuantizedSqrt_8)。这个 节点操作用于处理8位量化数据。	有提供int8版本的算子



HiFi-GAN模型导出



```
model = Generator(h).to(device)

state_dict_g = load_checkpoint(a.checkpoint_file, device)
model.load_state_dict(state_dict_g['generator'])
model.eval()

# 导出为ONNX格式
output_path = 'hifigan_model.onnx'
seq_len=1000 # 可变长度
input_tensor = torch.randn(1, 80, seq_len)

# 劝态轮廓设置
dynamic_axes = {'input': {2: 'seq_len'}, 'output': {2: 'seq_len'}}
torch.onnx.export(model, x, output_path, opset_version=11, verbose=False, dynamic_axes_dynamic_axes,input_names=['inputs'], output_names=['output'], do_constant_folding=True)
```

```
for i, filname in enumerate(filelist):
    wav, sr = load_wav(os.path.join(a.input_wavs_dir, filname))
    wav = wav / MAX_WAV_VALUE
    wav = torch.FloatTensor(wav).to(device)
    x = get_mel(wav.unsqueeze(0))
    x = x.to(torch.float32)
```





使用生成的 hifigan_model.onnx 文件进行推理 # 加载ONNX模型

```
# 加载ONNX模型
model_path = 'C:\\Users\\YodelYang\\Desktop\\Python\\hifi-gan-master\\hifigan_model.onnx'
session = onnxruntime.InferenceSession(model_path)

# 运行模型
start_time = time.time()
outputs = session.run(None,{"inputs": x.numpy()})
```

```
获取输出结果
output data = outputs[0]
output data tensor = torch.from numpy(output data)
output data tensor = output data tensor.cpu()
output data tensor = output data tensor * MAX WAV VALUE
output data array = output data tensor.numpy().astype('int16')
parser new = argparse.ArgumentParser()
parser_new.add_argument('--input_wavs_dir', default='generated files onnx')
parser new.add argument('--output dir', default='generated files onnx')
parser_new.add_argument('--checkpoint_file', required=True)
b = parser new.parse args()
output file = os.path.join(b.output dir, os.path.splitext(filname)[0] + ' generated onnx.wav')
write(output_file, h.sampling rate, output data array)
```





使用生成的 hifigan_model.onnx 文件进行推理

```
# 运行模型
start_time = time.time()
outputs = session.run(None,{"inputs": x.numpy()})
end_time = time.time()
elapsed2_time = end_time - start_time
print('Time consumption of existing methods: ', elapsed1_time, 'seconds')
print('Time consumption of onnx method:', elapsed2_time, 'seconds')
```

```
total_accuracy +=percentage
times+=1
print('Ratio of close elements:', percentage)
if times==100:
    break
```

```
Time consumption of existing methods: 2.716029644012451 seconds
Time consumption of onnx method: 1.1162590980529785 seconds
Ratio of close elements: 99.88922574626866
The total accuracy is 99.9
```



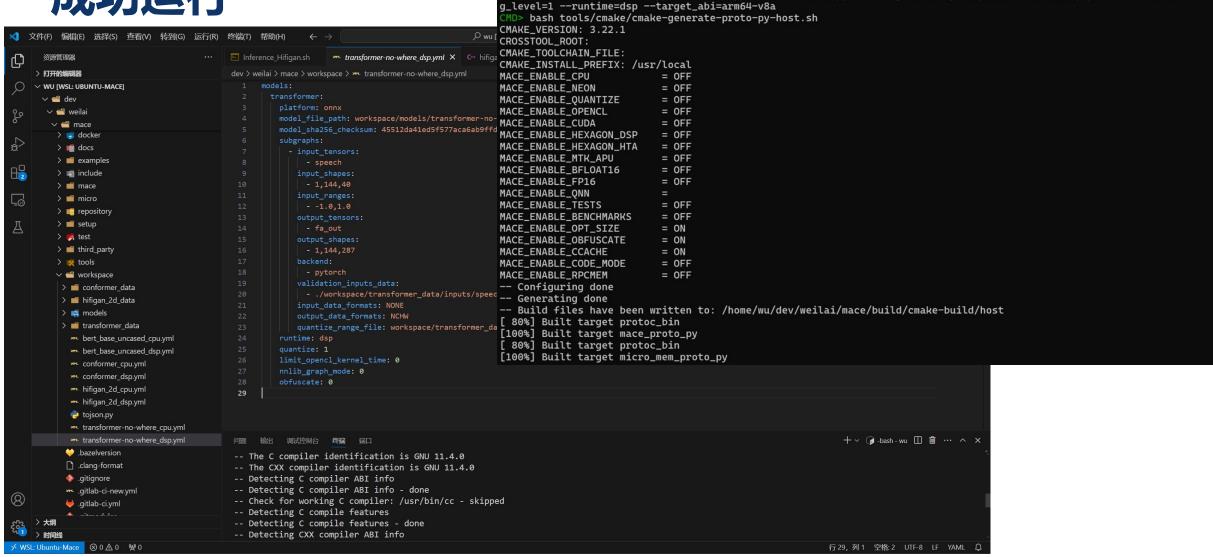
Linux和Android上C++版本的 OnnxRuntime测试



```
(mace) ~/dev/weilai/hexagon apps/onnxruntime/model/hifigan/cxx$ sudo bash Inference Hifigan.sh -1 00 -p linux
**************Command Params********
PLATFORM: linux
optim level: 00
python cost time: 2213.0 ms
output tensor shape: (1, 1, 66560, 1)
Success!
Compile Platform: linux
****** OnnxRuntime C++ Linux******
-- The C compiler identification is GNU 11.4.0
-- The CXX compiler identification is GNU 11.4.0
-- Detecting C compiler ABI info
  Detecting C compiler ABI info - done
-- Check for working C compiler: /usr/bin/cc - skipped
  Detecting C compile features
  Detecting C compile features - done
-- Detecting CXX compiler ABI info
  Detecting CXX compiler ABI info - done
  Check for working CXX compiler: /usr/bin/c++ - skipped
-- Detecting CXX compile features
  Detecting CXX compile features - done
  BUILD TYPE: Release
  OPTIMIAZATION LEVEL: 00
  Configuring done
-- Generating done
  Build files have been written to: /home/wu/dev/weilai/hexagon apps/onnxruntime/model/hifigan/cxx/build
[ 50%] Building CXX object CMakeFiles/Hifigan onnx linux.dir/hifigan onnx.cpp.o
[100%] Linking CXX executable ../Hifigan onnx linux
[100%] Built target Hifigan onnx linux
c++ cost time: 2314 ms
output tensor shape: 1 1 66560 1
Success!
```

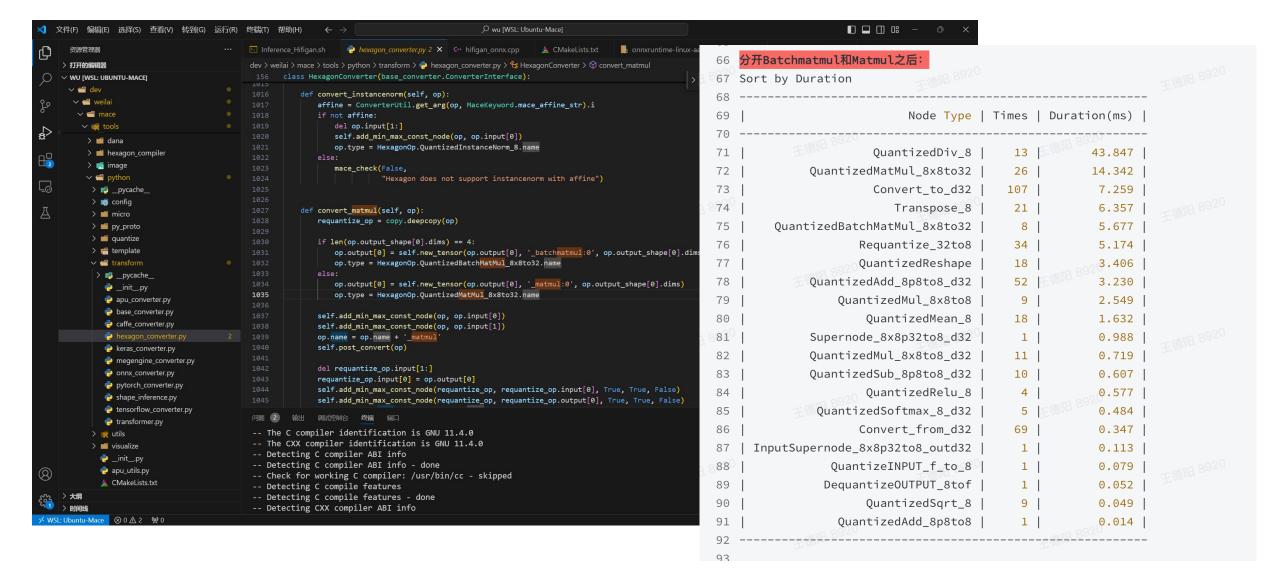


MACE框架下Transformer 成功运行 (mace) ~/dev/weilai/mace\$ python tools/python/run_model.py --config ./workspace/yml/conformer_dsp.yml --benchmark --vlo





Matmul和BatchMatmul算子 优化与性能提升



项目贡献



- 1. 深入理解了HiFi-GAN模型的理论基础和算法结构。
- 2. 成功导出了HiFi-GAN模型为ONNX格式,并验证了其导出模型的正确性和性能。
- 3. 优化和部署了ONNX模型在移动设备上的表现,通过性能测试和算子优化提升了模型的推理速度和效率。
- 4. 探索了MACE框架在移动端的应用,实现了模型的量化和性能优化。





请评委老师批评指正

答辩学生: 王德阳